

# **Сингулярное разложение и главные компоненты**

# Обобщение диагонализации

# Краткий план:

- Жорданова нормальная форма.

# Краткий план:

- Жорданова нормальная форма.
- Сингулярное разложение.

# Краткий план:

- Жорданова нормальная форма.
- Сингулярное разложение.
- Доказательство существования.

# Не все матрицы диагонализуемы

## Утверждение

Квадратная матрица  $A$  размера  $n \times n$  диагонализуема, если у неё найдётся  $n$  линейно независимых собственных векторов.

В этом случае  $A$  представима в виде  $A = PDP^{-1}$ , где  $P$  — матрица из собственных векторов,  $D$  — диагональная матрица из собственных значений.

# Не все матрицы диагонализуемы

## Утверждение

Квадратная матрица  $A$  размера  $n \times n$  диагонализуема, если у неё найдётся  $n$  линейно независимых собственных векторов.

В этом случае  $A$  представима в виде  $A = PDP^{-1}$ , где  $P$  — матрица из собственных векторов,  $D$  — диагональная матрица из собственных значений.

## Утверждение

У симметричной матрицы  $A$  размера  $n \times n$  найдётся  $n$  ортогональных собственных векторов единичной длины.

С их помощью матрица  $A$  представима в виде

$$A = PDP^T.$$

# А если не везёт?

Что делать, если у матрицы  $A$  размера  $n \times n$  меньше, чем  $n$  независимых собственных векторов?



# А если не везёт?

Что делать, если у матрицы  $A$  размера  $n \times n$  меньше, чем  $n$  независимых собственных векторов?

## Утверждение

Любая квадратная матрица  $A$  представима в виде

$$A = PJP^{-1},$$

где **жорданова нормальная форма**  $J$  содержит на диагонали **жордановы клетки**  $J_i$ :

$$J = \begin{pmatrix} J_1 & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & J_2 & \dots & \mathbf{0} \\ \dots & \dots & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \dots & J_k \end{pmatrix}, \quad J_i = \begin{pmatrix} \lambda_i & 1 & \dots & 0 \\ 0 & \lambda_i & \dots & 0 \\ 0 & \dots & \dots & 1 \\ 0 & 0 & \dots & \lambda_i \end{pmatrix}$$

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растягивание компонент вектора в  $\mathbb{R}^k$ .

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растягивание компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растягивание компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.
4. Ортогональное преобразование из  $\mathbb{R}^n$  в  $\mathbb{R}^n$ . Сохраняет длины векторов и углы между ними.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растягивание компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.
4. Ортогональное преобразование из  $\mathbb{R}^n$  в  $\mathbb{R}^n$ . Сохраняет длины векторов и углы между ними.

Все эти действия мы рассмотрели на первой лекции!

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .



# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

1. Повернём-отразим пространство, чтобы  $\mathbf{v}_1, \dots, \mathbf{v}_n$  перешли в  $\mathbf{e}_1, \dots, \mathbf{e}_n$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

1. Повернём-отразим пространство, чтобы  $\mathbf{v}_1, \dots, \mathbf{v}_n$  перешли в  $\mathbf{e}_1, \dots, \mathbf{e}_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

1. Повернём-отразим пространство, чтобы  $\mathbf{v}_1, \dots, \mathbf{v}_n$  перешли в  $\mathbf{e}_1, \dots, \mathbf{e}_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.
3. Смены размерности нет.

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

1. Повернём-отразим пространство, чтобы  $\mathbf{v}_1, \dots, \mathbf{v}_n$  перешли в  $\mathbf{e}_1, \dots, \mathbf{e}_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.
3. Смены размерности нет.
4. Повернём-отразим пространство, чтобы  $\mathbf{e}_1, \dots, \mathbf{e}_n$  перешли в  $\mathbf{v}_1, \dots, \mathbf{v}_n$ .

# Сингулярное разложение

## Утверждение

Любую матрицу  $A$  размера  $n \times k$  можно представить в виде

$$A = U\Sigma V^T,$$

где матрица  $U$  размера  $n \times n$  — ортогональная,  $U^T U = I$ ,

матрица  $V$  размера  $k \times k$  — ортогональная,  $V^T V = I$ ,

матрица  $\Sigma$  размера  $n \times k$  — диагональная.

# Сингулярное разложение

## Утверждение

Любую матрицу  $A$  размера  $n \times k$  можно представить в виде

$$A = U\Sigma V^T,$$

где матрица  $U$  размера  $n \times n$  — ортогональная,  $U^T U = I$ ,

матрица  $V$  размера  $k \times k$  — ортогональная,  $V^T V = I$ ,

матрица  $\Sigma$  размера  $n \times k$  — диагональная.

Данное разложение также называется *SV D-разложением*,  
singular value decomposition.



# Присмотримся к матрицам

Если  $n \geq k$ , то  $SVD$ -разложение примет вид

$$A = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \cdot \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} - & \mathbf{v}_1^T & - \\ \vdots \\ - & \mathbf{v}_k^T & - \end{pmatrix}$$

# Присмотримся к матрицам

Если  $n \geq k$ , то  $SVD$ -разложение примет вид

$$A = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \cdot \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} - & \mathbf{v}_1^T & - \\ \vdots \\ - & \mathbf{v}_k^T & - \end{pmatrix}$$

Числа  $\sigma_i$  называются **сингулярными** числами матрицы  $A$ .

# Зачем нужно $SVD$ -разложение?

Сильно упрощает многие вычисления.

# Зачем нужно $SVD$ -разложение?

Сильно упрощает многие вычисления.

Показывает внутренний мир матрицы.

# Зачем нужно $SV D$ -разложение?

Сильно упрощает многие вычисления.

Показывает внутренний мир матрицы.

Существует быстрая и устойчивая итеративная процедура нахождения  $SV D$ -разложения.

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

Сингулярное разложение для  $A^T A$ :

$$A^T A = V\Sigma^T U^T \cdot U\Sigma V^T = V\Sigma^T \Sigma V^T$$

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

Сингулярное разложение для  $A^T A$ :

$$A^T A = V\Sigma^T U^T \cdot U\Sigma V^T = V\Sigma^T \Sigma V^T$$

Сингулярное разложение для  $AA^T$ :

$$AA^T = U\Sigma V^T \cdot V\Sigma^T U^T = U\Sigma\Sigma^T U^T$$



# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .
3. Осталось найти  $U$  из целевого разложения:

$$A = U\Sigma V^T$$

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .
3. Осталось найти  $U$  из целевого разложения:

$$A = U\Sigma V^T \text{ или } AV = U\Sigma$$

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = Av_1/\sigma_1,$$

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = Av_1/\sigma_1, \quad u_2 = Av_2/\sigma_2, \dots$$



# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = Av_1/\sigma_1, u_2 = Av_2/\sigma_2, \dots$$

5. Вектора  $v_i$  кончатся раньше  $u_i$ .

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = Av_1/\sigma_1, u_2 = Av_2/\sigma_2, \dots$$

5. Вектора  $v_i$  кончатся раньше  $u_i$ . Оставшиеся  $u_{k+1}, \dots, u_n$  выберем произвольными, чтобы  $U$  была ортогональной матрицей.

# Поиск $SVD$ разложения

Это видеофрагмент с доской, слайдов здесь нет :)

# Нахождение проекции при известном SVD

Это видеофрагмент с доской, слайдов здесь нет :)

# Немного статистики

# Краткий план:

- Выборочная дисперсия.

# Краткий план:

- Выборочная дисперсия.
- Стандартизация.

# Краткий план:

- Выборочная дисперсия.
- Стандартизация.
- Выборочная корреляция.



# Центрирование

## Определение

Для вектора чисел  $x = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

# Центрирование

## Определение

Для вектора чисел  $x = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

## Определение

**Центрирование переменной** — переход от набора чисел  $(x_1, x_2, \dots, x_n)$  к набору чисел  $(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$ .

# Центрирование

## Определение

Для вектора чисел  $x = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

## Определение

**Центрирование переменной** — переход от набора чисел  $(x_1, x_2, \dots, x_n)$  к набору чисел  $(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$ .

Пример.  $(4, 2, 3, 3) \rightarrow (1, -1, 0, 0)$ .

# Свойства центрирования

## Утверждение

Если  $x'$  — это центрированный вектор  $x$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

# Свойства центрирования

## Утверждение

Если  $x'$  — это центрированный вектор  $x$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

# Свойства центрирования

## Утверждение

Если  $x'$  — это центрированный вектор  $x$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

С геометрической точки зрения:

$(\bar{x}, \bar{x}, \dots, \bar{x})$  — проекция вектора  $x$  на  $\text{Span } \mathbf{v}$ , где  $\mathbf{v} = (1, 1, \dots, 1)$ .

# Свойства центрирования

## Утверждение

Если  $x'$  — это центрированный вектор  $x$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

С геометрической точки зрения:

$(\bar{x}, \bar{x}, \dots, \bar{x})$  — проекция вектора  $x$  на  $\text{Span } \mathbf{v}$ , где  $\mathbf{v} = (1, 1, \dots, 1)$ .

$(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$  — проекция вектора  $x$  на  $\text{Span}^\perp \mathbf{v}$ .

# Выборочная дисперсия

## Определение

**Выборочной дисперсией** набора чисел  $(x_1, x_2, \dots, x_n)$  называют величину  $\|\mathbf{x}'\|^2 / (n - 1)$ , где вектор  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ .

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$



# Выборочная дисперсия

## Определение

**Выборочной дисперсией** набора чисел  $(x_1, x_2, \dots, x_n)$  называют величину  $\|\mathbf{x}'\|^2 / (n - 1)$ , где вектор  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ .

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$

Выборочная дисперсия вектора показывает «разброс»  $x_i$ , насколько далеки  $x_i$  от своего среднего  $\bar{x}$ .

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

**Выборочным стандартным отклонением** набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

**Выборочным стандартным отклонением** набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

**Выборочным стандартным отклонением** набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

Если  $x_i$  измеряется в сантиметрах, то выборочное стандартное отклонение измеряется в сантиметрах.

# Стандартизация

Популярным вариантом масштабирования переменной является переход к безразмерной величине по принципу:

$$x_i \rightarrow \frac{x_i - \bar{x}}{sd(\mathbf{x})}.$$

# Стандартизация

Популярным вариантом масштабирования переменной является переход к безразмерной величине по принципу:

$$x_i \rightarrow \frac{x_i - \bar{x}}{sd(\mathbf{x})}.$$

После стандартизации величина имеет нулевое среднее и единичное стандартное отклонение.

# Выборочная корреляция

## Определение

**Выборочной корреляцией** двух наборов чисел  $x$  и  $y$  называют косинус угла между их центрированными версиями:

$$\rho(\mathbf{x}, \mathbf{y}) = \cos \angle(\mathbf{x}', \mathbf{y}') = \frac{\langle \mathbf{x}', \mathbf{y}' \rangle}{\|\mathbf{x}'\| \|\mathbf{y}'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .



# Выборочная корреляция

## Определение

**Выборочной корреляцией** двух наборов чисел  $x$  и  $y$  называют косинус угла между их центрированными версиями:

$$\rho(\mathbf{x}, \mathbf{y}) = \cos \angle(\mathbf{x}', \mathbf{y}') = \frac{\langle \mathbf{x}', \mathbf{y}' \rangle}{\|\mathbf{x}'\| \|\mathbf{y}'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .

Не определена, если  $x$  или  $y$  состоит из одинаковых чисел.

# Выборочная корреляция

## Определение

**Выборочной корреляцией** двух наборов чисел  $x$  и  $y$  называют косинус угла между их центрированными версиями:

$$\rho(\mathbf{x}, \mathbf{y}) = \cos \angle(\mathbf{x}', \mathbf{y}') = \frac{\langle \mathbf{x}', \mathbf{y}' \rangle}{\|\mathbf{x}'\| \|\mathbf{y}'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .

Не определена, если  $x$  или  $y$  состоит из одинаковых чисел.

Лежит в диапазоне от  $-1$  до  $1$ .

# Выборочная корреляция

## Утверждение

Выборочная корреляция равна

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}.$$

Если после центрирования векторы ортогональны, то выборочная корреляция равна 0.

# Выборочная корреляция

## Утверждение

Выборочная корреляция равна

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}.$$

Если после центрирования векторы ортогональны, то выборочная корреляция равна 0.

Не чувствительна к масштабированию.

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(x_i, x_j)$$

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(x_i, x_j)$$

Если переменные  $x_1, x_2, \dots, x_k$  стандартизированы, то  $C = X^T X$ .

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(x_i, x_j)$$

Если переменные  $x_1, x_2, \dots, x_k$  стандартизированы, то  $C = X^T X$ .

Матрица  $C$  симметрична и положительно полуопределена.

**РСА: максимизация разброса**



# Краткий план:

- Последовательное построение компонент.

# Краткий план:

- Последовательное построение компонент.
- Свойства компонент.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

А мы хотим визуализировать данные.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

А мы хотим визуализировать данные.

Или хотим иметь небольшое количество переменных, которые бы почти без потерь содержали всю информацию в исходных переменных.

# Метод главных компонент

Все исходные переменные предварительно стандартизируем!

# Метод главных компонент

Все исходные переменные предварительно стандартизируем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .



# Метод главных компонент

Все исходные переменные предварительно стандартизируем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .  
На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

# Метод главных компонент

Все исходные переменные предварительно стандартизируем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

Новые переменные будем создавать по-очередности.

# Метод главных компонент

Все исходные переменные предварительно стандартизируем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

Новые переменные будем создавать по-очереди.

Новые переменные будем называть **главными компонентами**.

PCA — **principal component analysis**.

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .
2. Компоненту  $p_2 = Xv_2$  подберём так, чтобы выборочная дисперсия  $p_2$  была максимальной при условии, что  $v_2 \perp v_1$  и  $\|v_2\| = 1$ .

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .
2. Компоненту  $p_2 = Xv_2$  подберём так, чтобы выборочная дисперсия  $p_2$  была максимальной при условии, что  $v_2 \perp v_1$  и  $\|v_2\| = 1$ .
3. Компоненту  $p_3 = Xv_3$  подберём так, чтобы выборочная дисперсия  $p_3$  была максимальной при условии, что  $v_3 \perp v_2, v_1$  и  $\|v_3\| = 1$ .
4. ...

# Картинка



# Это завуалированный $SVD$ !

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

# Это завуалированный $SVD$ !

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

$$\begin{pmatrix} | & & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & & | \end{pmatrix} = \begin{pmatrix} | & & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_k \\ | & & | \end{pmatrix} \begin{pmatrix} | & & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_k \\ | & & | \end{pmatrix}$$
$$\begin{pmatrix} | & & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & & | \end{pmatrix} = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

# Это завуалированный $SVD$ !

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

$$\begin{pmatrix} | & & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & & | \end{pmatrix} = \begin{pmatrix} | & & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_k \\ | & & | \end{pmatrix} \begin{pmatrix} | & & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_k \\ | & & | \end{pmatrix}$$
$$\begin{pmatrix} | & & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & & | \end{pmatrix} = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

# Несколько соотношений

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

# Несколько соотношений

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

Главные компоненты ортогональны.

Если  $X = U\Sigma V^T$ , то корреляционная матрица имеет вид

$$C = X^T X = V\Sigma^T \Sigma V^T.$$

# Несколько соотношений

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

Главные компоненты ортогональны.

Если  $X = U\Sigma V^T$ , то корреляционная матрица имеет вид

$$C = X^T X = V\Sigma^T \Sigma V^T.$$

Векторы весов  $\mathbf{v}_i$ , с которыми исходные переменные входят в компоненты, являются собственными векторами матрицы  $C$ .

Сингулярные значения матрицы  $X$  в квадрате являются собственными числами корреляционной матрицы  $C$ ,

$$\lambda_i = \sigma_i^2.$$

## Скринкаст: SVD для снижения размерности

Это видеофрагмент с доской, слайдов здесь нет :)

## **Бонус: геометрическая алгебра**

Это видеофрагмент с доской, слайдов здесь нет :)